

Sprawy organizacyjne

- Wykład: 9:30–11:00 (sala 105)
- Ćwiczenia: 11:15–12:00 (sala 105)
- Laboratoria: 12:30–14:00 (sala 219)

Punktacja (min. 50 pkt. na ocenę 3.0):

- Egzamin: 0–50 pkt.
- Kolokwium: 0–20 pkt.
- 5× zadanie z labów: 0–20 pkt.
- 4× kartkówki: 0–10 pkt.
- Aktywność na ćwiczeniach: 0–10 pkt.

Strona prowadzącego: <http://pages.mim.pw.edu.pl/~joziakp/os>

Literatura:

- 1–5: różne źródła,
 - 6–10: *Introduction to Stochastic Search & Optimization* — James C. Spall,
 - 11–15: *Monte Carlo Statistical Methods* — Ch. Robert, G. Casella.
-

Czym zajmuje się optymalizacja stochastyczna?

Zagadnienia postaci:

$$x^* = \arg \min_{x \in S} f(x).$$

- 1) $\nabla f(x) = 0 \longrightarrow$ zbiór punktów krytycznych $\longrightarrow$ wśród nich może być minimum.
Ale: równanie $\nabla f(x) = 0$ może być bardzo trudne do rozwiązywania analitycznie.

- 2) Przybliżone rozwiązanie można uzyskać metodą kroku gradientowego.

Ale:

- zbieżność tylko do minimum lokalnego,
- ∇ może być trudny/nieemożliwy do policzenia.

Przykład. Szukamy $x^* = \arg \min_{x \in S} f(x)$, ale obserwujemy jedynie $g(x, \omega)$ takie, że $f(x) = \mathbb{E}[g(x, \omega)]$, gdzie ω to element przestrzeni probabilistycznej.

Np. $g(x, \omega) = f(x) + Z(\omega)$, gdzie $Z(\omega) \sim \mathcal{N}(0, \nu^2)$ jest szumem.

Algorytm 1 (Przeszukiwanie Stochastyczne — PRS, *Pure Random Search*)

Znaleźć $x^* = \arg \min_{x \in S} f(x)$, gdzie f jest ciągła, $S \subseteq \mathbb{R}^d$.

Weźmy rozkład $\delta: \mathcal{B}(S) \rightarrow [0, 1]$.

- **Krok 0:** $y_0 \sim \delta$, $x_0 = y_0$.
- **Krok 1:** $y_{k+1} \sim \delta$, $x_{k+1} = \begin{cases} y_{k+1} & : f(y_{k+1}) < f(x_k), \\ x_k & : \text{wpp.} \end{cases}$
- **Krok 2:** $k += 1$.

Przerwywamy, gdy k przekroczy ustalony wcześniej limit.

Model matematyczny PRS

Niech $X_k = X_k(\omega)$, $Y_k = Y_k(\omega)$ dla pewnej $\omega \in \Omega$.

Zakładamy, że $Y_0, Y_1, \dots \stackrel{\text{iid}}{\sim} \delta$ oraz

$$X_{k+1} = \begin{cases} Y_{k+1} & : f(Y_{k+1}) < f(X_k), \\ X_k & : \text{wpp.} \end{cases}$$

Oznaczamy:

$$\begin{aligned} m &:= \min_{x \in S} f(x), \\ S_\varepsilon &:= \{x \in S : f(x) < m + \varepsilon\}, \\ X^* &:= \{x \in S : f(x) = m\}. \end{aligned}$$

Twierdzenie 1

Jeśli f ciągła, to przy powyższych oznaczeniach:

$$\begin{aligned} \mathbb{P}(X_k \xrightarrow{k \rightarrow \infty} X^*) &= 1, \\ \mathbb{P}(\{\omega \in \Omega : d(X_k(\omega), X^*) \xrightarrow{k \rightarrow \infty} 0\}) &= 1. \end{aligned}$$

Dowód. 1) Ciąg $f(X_k)$ jest nierosnący i ograniczony z dołu przez m (dla każdego $\omega \in \Omega$), więc z twierdzenia Bolzano–Weierstrassa jest zbieżny do $\eta(\omega) \geq m$.

2) Ustalmy $\varepsilon > 0$. Niech

$$R_k = \{\omega \in \Omega : f(Y_k(\omega)) < m + \varepsilon\} = Y_k^{-1}(S_\varepsilon)$$

— zdarzenia niezależne.

3) $\mathbb{P}(R_k) = \mathbb{P}(Y_k^{-1}(S_\varepsilon)) = \delta(S_\varepsilon) =: \alpha > 0$.

Z Lematu Borela–Cantelliego: $(\Omega, \mathcal{F}, \mathbb{P})$ — przestrzeń probabilistyczna, $R_1, R_2, \dots$

— zdarzenia niezależne,

$$\sum_{k \geq 1} \mathbb{P}(R_k) = +\infty \implies \mathbb{P}\left(\bigcap_{t=1}^{\infty} \bigcup_{i=t}^{\infty} R_i\right) = 1.$$

4) $\eta \geq m + \varepsilon \implies \forall k \ f(Y_k) \geq \eta \geq m + \varepsilon$, zatem

$$\{\omega \in \Omega : \eta(\omega) \geq m + \varepsilon\} \subseteq \bigcap_{k=1}^{\infty} (\Omega \setminus R_k) = \Omega \setminus \bigcup_{k=1}^{\infty} R_k,$$

$$\{\omega \in \Omega : \eta(\omega) \leq m + \varepsilon\} \supseteq \bigcup_{k=1}^{\infty} R_k \supseteq \bigcap_{t=1}^{\infty} \bigcup_{i=t}^{\infty} R_i,$$

więc $\mathbb{P}(\{\omega \in \Omega : \eta(\omega) \leq m + \varepsilon\}) = 1$.

□

Zalety PRS:

- łatwość implementacji,
- używa tylko pomiarów funkcji f ,
- rozsądny koszt obliczeniowy,
- ogólność,
- mocne ugruntowanie teoretyczne.

Algorytm 2 (Localized Random Search)

- **Krok 0:** ustalam punkt początkowy x_0 (losowo albo na podstawie wiedzy o problemie).
- **Krok 1:** losujemy $d_k \in \mathbb{R}^d$. Jeśli $x_k + d_k \in S$, to $y_{k+1} = x_k + d_k$.
Wpp. $y_{k+1} = \arg \min_{x \in S} \|x - (x_k + d_k)\|$ (najbliższy $x_k + d_k$ punkt z S).
- **Krok 2:** $x_{k+1} = \begin{cases} y_{k+1} & : f(y_{k+1}) < f(x_k), \\ x_k & : \text{wpp.} \end{cases}$
- **Krok 3:** $k \leftarrow k + 1$

Całość powtarzamy dopóki nie przekroczymy ustalonego limitu na k .

Typowo $d_k \sim \mathcal{N}_d$ (wielowymiarowy normalny) oraz wariancja maleje ze wzrostem k . Wtedy algorytm stabilizuje się, mamy mniejsze „skoki”.

Twierdzenie 2

$f: S \rightarrow \mathbb{R}$ ciągła, $m := \min_{x \in S} f(x)$, $X^* := \{x \in S : f(x) = m\}$.

Rozważmy wariant algorytmu z $d_k \sim \mathcal{N}_d(0, I_d)$. Losujemy, dopóki $x_k + d_k \in S$.

Niech $\varepsilon > 0$, niech $S_\varepsilon := \{x \in S : f(x) < m + \varepsilon\}$. Wtedy

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_k \in S_\varepsilon) = 1.$$

Algorytm 3 (Poprawiony Localized Random Search)

- **Krok 0:** ustal $x_0 \in S$ losowo bądź na podstawie wiedzy o problemie. $k = 0$, $b_k = 0$.
- **Krok 1:** losujemy niezależnie $d_k \sim \mathcal{N}_d(b_k, \sigma^2 I_d)$. Jeśli $x_k + d_k \notin S$, to losujemy ponownie lub rzutujemy $x_k + d_k$ na S .
- **Krok 2:** (wektor)

$$\begin{bmatrix} x_{k+1} \\ b_{k+1} \end{bmatrix} = \begin{cases} \begin{bmatrix} x_k + d_k \\ (2d_k - b_k)/5 \end{bmatrix} & \text{jeśli } f(x_k + d_k) < f(x_k), \\ \begin{bmatrix} x_k + 2b_k - d_k \\ (7b_k - 2d_k)/5 \end{bmatrix} & : f(x_k + 2b_k - d_k) < f(x_k), \\ \begin{bmatrix} x_k \\ \frac{1}{2}b_k \end{bmatrix} & \text{wpp.} \end{cases}$$

- **Krok 3:** $k += 1$; jeśli kryterium stopu $\rightarrow$ koniec, wpp. $\rightarrow$ Krok 1.

Tempo zbieżności PRS I

Naszym celem jest szacowanie liczby kroków, po której $X_k \in S_\varepsilon$ ($\varepsilon > 0$ ustalony, reprezentuje tolerancję na odchylenie od minimum). Oznaczamy

$$\rho(\varepsilon) := \delta(S_\varepsilon)$$

i zakładamy, że $\rho(\varepsilon) > 0$ (w przeciwnym razie algorytm nigdy nie trafi do S_ε).

Redukcja do prób Bernoulliego. Z definicji X_k mamy $f(X_k) = \min_{j \leq k} f(Y_j)$ (indukcja po k : w każdym kroku zostawiamy lepszy z punktów Y_{k+1}, X_k). Przynależność do S_ε zależy tylko od wartości f , więc

$$\{X_k \in S_\varepsilon\} = \bigcup_{j \leq k} \{Y_j \in S_\varepsilon\},$$

czyli „do kroku k trafiliśmy do S_ε ” $\iff$ „choć jedno losowanie Y_j wpadło do S_ε ”. Zdarzenia $\{Y_k \in S_\varepsilon\}$ są niezależne i każde ma prawdopodobieństwo $\delta(S_\varepsilon) = \rho(\varepsilon)$, zatem szansa, że nie odwiedzimy tego zbioru w krokach $1, 2, \dots, n$, wynosi

$$\mathbb{P}(X_n \notin S_\varepsilon) = \prod_{k=1}^n (1 - \mathbb{P}(Y_k \in S_\varepsilon)) = (1 - \rho(\varepsilon))^n.$$

Liczba kroków przy zadanej pewności. Ile kroków potrzeba, by trafić do S_ε z prawdopodobieństwem $\geq 1 - \gamma$ (dla małego $\gamma \in (0, 1)$)? Ponieważ $\log(1 - \rho(\varepsilon)) < 0$, dzielenie przez tę liczbę odwraca nierówność:

$$\begin{aligned} 1 - (1 - \rho(\varepsilon))^n &\geq 1 - \gamma \iff (1 - \rho(\varepsilon))^n \leq \gamma \\ &\iff n \log(1 - \rho(\varepsilon)) \leq \log \gamma \\ &\iff n \geq \frac{\log \gamma}{\log(1 - \rho(\varepsilon))}. \end{aligned}$$

Oba logarytmy są ujemne, więc prawa strona jest dodatnia. Z nierówności $\log(1 - t) \leq -t$ dla $t \in [0, 1)$ dostajemy wygodniejsze oszacowanie

$$\frac{\log \gamma}{\log(1 - \rho(\varepsilon))} \leq \frac{\log(1/\gamma)}{\rho(\varepsilon)},$$

czyli koszt rośnie jak $1/\rho(\varepsilon)$, a od żądanej pewności zależy jedynie logarytmicznie.

Czas pierwszego trafienia. Niech

$$N(\varepsilon) := \min\{k : X_k \in S_\varepsilon\} = \min\{k : Y_k \in S_\varepsilon\} = \min\{k : f(Y_k) < m + \varepsilon\}$$

(druga równość to znów fakt, że $f(X_k)$ jest minimum dotychczasowych wartości). Zatem $N(\varepsilon)$ to numer pierwszego sukcesu w ciągu niezależnych prób Bernoulliego z prawdopodobieństwem sukcesu $\rho(\varepsilon)$:

$$\mathbb{P}(N(\varepsilon) = n) = (1 - \rho(\varepsilon))^{n-1} \rho(\varepsilon),$$

czyli $N(\varepsilon) \sim \text{Geo}(\rho(\varepsilon))$, skąd

$$\mathbb{E}[N(\varepsilon)] = \frac{1}{\rho(\varepsilon)}, \quad \text{Var}[N(\varepsilon)] = \frac{1 - \rho(\varepsilon)}{\rho(\varepsilon)^2}.$$

Przypadek rozkładu jednostajnego. Niech $S \subseteq \mathbb{R}^d$ będzie ograniczony o mierze $|S| \in (0, \infty)$, a δ — rozkładem jednostajnym na S , tzn. $\rho(\varepsilon) = |S_\varepsilon|/|S|$. Ustalmy $x^* \in X^*$; z ciągłości f istnieje $\varepsilon' > 0$ takie, że $B(x^*, \varepsilon') \subseteq S_\varepsilon$. Ponieważ $|B(x^*, \varepsilon')| = c_d \cdot (\varepsilon')^d$, mamy $\rho(\varepsilon) \geq c_d(\varepsilon')^d/|S|$, a więc

$$\mathbb{E}[N(\varepsilon)] \leq \frac{|S|}{c_d \cdot (\varepsilon')^d},$$

z równością, gdy $S_\varepsilon = B(x^*, \varepsilon')$. Kluczowa jest tu zależność $(\varepsilon')^{-d}$: oczekiwany czas rośnie wykładniczo z wymiarem d („przekleństwo wymiaru”), np. dziesięciokrotne zmniejszenie promienia tolerancji mnoży koszt przez 10^d .

Algorytm 4 (Pure Adaptive Search)

- **Krok 0:** ustalmy $x_0 \in S$ (losowo lub na podstawie wiedzy o problemie).
 $k = 0$, $w_0 = f(x_0)$.
- **Krok 1:** losuj x_{k+1} z rozkładu jednostajnego na

$$S_k = \{x \in S : f(x) < w_k\}.$$

- **Krok 2:** $k += 1$. Jeśli kryterium stopu spełnione $\longrightarrow$ koniec, wpp. $\longrightarrow$ Krok 1.
-

Teoria rekordów

Niech $X_1, X_2, \dots$ — ciąg zmiennych losowych iid o wspólnej dystrybucji $F(x)$.

Konstruujemy ciąg zmiennych losowych $N(k)$ w następujący sposób:

$$\begin{aligned} N(1) &= 1, \\ N(k) &= \min \{j > N(k-1) : X_j > X_{N(k-1)}\} \\ &= \min \{j > N(k-1) : X_j > \max(X_1, \dots, X_{N(k-1)})\}. \end{aligned}$$

Wtedy $\mathbb{P}(N(k) < \infty) = 1$, zatem $\forall k \quad p_{n,k} := \mathbb{P}(N(k) = n)$, więc $p_{n,k}$ jest rozkładem prawdopodobieństwa na $\mathbb{N}$.

Lemat. *Jeśli $F(x)$ to funkcja ciągła, to rozkład $N(k)$ nie zależy od F .*

Dowód. Ćwiczenie.

□