

Optymalizacje Stochastyczne, wykład 1, 2026-10-05

Wykład: 9:30-11:00 } sala 105
Ćwiczenie: 11:15-12:00 }

Laboratoria: 12:30-14:00 } sala 219

Egzamin: 0-50 pkt.

Kolokwium: 0-20 pkt.

5x zaliczenie z labów: 0-20 pkt.

4x kartkówki: 0-10 pkt.

Aktywność ćwiczenia: 0-10 pkt.

min 50 pkt.
na ocenę 3.0

Strona prowadzącego:

<http://pages.mim.pw.edu.pl/~njoziakp/os>

Literatura:

1-5: różne źródła

6-10: "Introduction to Stochastic Search & Optimization"
— James C. Spall

11-15: "Monte Carlo Statistical Methods"
— Ch. Robert, G. Casella

Czym zajmuje się optymalizacja stochastyczna?

Zegadnienie postaci:

$$x^* = \underset{x \in S}{\operatorname{argmin}} f(x)$$

1) $\nabla f(x) = 0 \rightarrow$ zbiór punktów krytycznych $\rightarrow$
 $\rightarrow$ wśród nich może być minimum

Ale: Równanie $\nabla f(x) = 0$ może być bardzo trudne do rozwiązania analitycznie

2) Przybliżone rozwiązanie można uzyskać metodą kroku gradientowego.

Ale:

- Zbieżność tylko do równania lokalnego

- ∇ może być trudny/nieemożliwy do policzenia

Przykład:

Szukamy $x^* = \underset{x \in S}{\operatorname{argmin}} f(x)$, ale obserwujemy

jedynie $g(x, \omega)$ t.ż. $f(x) = \mathbb{E}[g(x, \omega)]$

↑
omega

szum
↓

np. $g(x, \omega) = f(x) + Z(\omega)$, gdzie $Z(\omega) \sim N(0, \sigma^2)$

— Algorytm:

Przeszukiwanie Stochastyczne (PRS)

↑
Pure Random Search

Znaleźć $x^* = \underset{x \in S}{\operatorname{argmin}} f(x)$, gdzie f - ciągła, $S \subseteq \mathbb{R}^d$

Weźmy rozkład $\delta: \mathcal{B}(S) \rightarrow [0, 1]$

Krok 0: $y_0 \sim \delta$, $x_0 = y_0$

Krok 1: $y_{k+1} \sim \delta$, $x_{k+1} = \begin{cases} y_{k+1} : f(y_{k+1}) < f(x_k) \\ x_k : \text{wpp} \end{cases}$

Krok 2: $k += 1$

Przerywamy, gdy k przekroczy ustalony limit.

Model matematyczny:

$$X_k = X_k(\omega), \quad Y_k = Y_k(\omega)$$

Zakładamy, że $Y_0, Y_1, \dots \stackrel{iid}{\sim} \mathcal{S}$

$$X_{k+1} = \begin{cases} Y_{k+1} & : f(Y_{k+1}) < f(X_k) \\ X_k & : \text{wpp} \end{cases}$$

Określamy: $m := \min_{x \in S} f(x)$

$$S_\varepsilon := \{x \in S : f(x) < m + \varepsilon\}$$

$$X^* := \{x \in S : f(x) = m\}$$

Tw:

Jeśli f ciągła, to przy powyższych założeniach:

$$\mathbb{P}(X_k \xrightarrow{k \rightarrow \infty} X^*) = 1$$

$$\mathbb{P}(\{\omega \in \mathcal{X} : d(X_k(\omega), X^*) \xrightarrow{k \rightarrow \infty} 0\}) = 1$$

Daw:

1) Ciąg $f(X_k)$ jest nierosnący i ograniczony z dołu przez m (dla każdego $\omega \in \mathcal{X}$)

$\Rightarrow$ zbieżny do $\eta(\omega) \geq m$
tw. Bolzano
Weierstrassa

2) Ustalony $\varepsilon > 0$.

Niech

$$R_k = \{ \omega \in \mathcal{X} : f(Y_k(\omega)) < m + \varepsilon \} = Y_k^{-1}(S_\varepsilon) \text{ —}$$

— zdarzenie niezależne

$$3) \mathbb{P}(R_k) = \mathbb{P}(Y_k^{-1}(S_\varepsilon)) = \mathbb{P}(S_\varepsilon) =: \alpha > 0$$

Z Lematu Borella-Cantelliego:

$(\mathcal{X}, \mathcal{F}, \mathbb{P})$ — przestrz. prob., $R_1, R_2, \dots$ — zdarzenia niezależne.

$$\sum_{k \geq 1} \mathbb{P}(R_k) = +\infty \Rightarrow \mathbb{P}\left(\bigcap_{t=1}^{\infty} \bigcup_{i=t}^{\infty} R_i\right) = 1$$

$$4) \eta \geq m + \varepsilon \Rightarrow \bigvee_k f(Y_k) \geq \eta \geq m + \varepsilon$$

$$\{\omega \in \mathcal{X} : \eta(\omega) \geq m + \varepsilon\} \subseteq \bigcap_{k=1}^{\infty} (\mathcal{X} \setminus R_k) = \mathcal{X} \setminus \bigcup_{k=1}^{\infty} R_k$$

$$\{\omega \in \mathcal{X} : \eta(\omega) \leq m + \varepsilon\} \supseteq \bigcup_{k=1}^{\infty} R_k \supseteq \bigcap_{t=1}^{\infty} \bigcup_{i=t}^{\infty} R_i$$

$$\text{więc } \mathbb{P}(\{\omega \in \mathcal{X} : \eta(\omega) \leq m + \varepsilon\}) = 1.$$

□

Zalety PRS:

- łatwość implementacji
- używa tylko pomiarów funkcji f
- rozsądny koszt obliczeniowy
- ogólność
- mocne ugruntowanie teoretyczne

Algorytm: Localized Random Search

Krok 0: ustalam punkt początkowy x_0
(losowo, albo na podstawie wiedzy o problemie)

Krok 1:

Losujemy $d_k \in \mathbb{R}^d$. Jeśli $x_k + d_k \in S$ to

$$y_{k+1} = x_k + d_k.$$

$$\text{Wpp. } y_{k+1} = \underset{x \in S}{\operatorname{argmin}} \|x - (x_k + d_k)\|$$

(najbliższy $x_k + d_k$ punkt z S)

Krok 2:

$$x_{k+1} = \begin{cases} y_{k+1} & : f(y_{k+1}) < f(x_k) \\ x_k & : \text{wpp.} \end{cases}$$

Krok 3:

$k+1$ dopóki nie przekroczymy ustalonego limitu.

Typowo $d_k \sim \mathcal{N}_d \leftarrow$ wielowymiarowy normalny
Oraz wariancje maleje ze wzrostem k .

Wtedy algorytm stabilizuje się, mamy mniej "skoki".

Tw:

$f: S \rightarrow \mathbb{R}$ ciągła, $m := \min_{x \in S} f(x)$,

$$X^* := \{x \in S : f(x) = m\}.$$

Rozważmy wariant algorytmu z $d_k \sim N_d(0, I_d)$.

Losujemy dopóki $X_k + d_k \in S$.

Niech $\varepsilon > 0$, niech $S_\varepsilon := \{x \in S : f(x) < m + \varepsilon\}$.

Wtedy $\lim_{k \rightarrow \infty} P(X_k \in S_\varepsilon) = 1$

Predmioty Fakultatywne

ekonomia 1.2,

wstęp do matematyki
↑
finansowej

wszystkie z Kobos, nie trzeba dobrać
na zajęciach

wstęp do uczenia maszynowego (nieoficjalnie)

szwedzi czasowe

Algorytm: Poprawiony Localized Random Search

Krok 0:

Ustal $x_0 \in S$ losowo bądź na podstawie wiedzy o problemie. $k=0$, $b_k = 0$

Krok 1:

Losujemy niezależnie $d_k \sim \mathcal{N}_d(b_k, \sigma^2 I_d)$.

Jeśli $x_k + d_k \notin S$ to losujemy ponownie lub
zwracamy $x_k + d_k \in S$

Krok 2: *wektor*

$$\begin{array}{c} \downarrow \\ \begin{bmatrix} x_{k+1} \\ b_{k+1} \end{bmatrix} = \begin{cases} \begin{bmatrix} x_k + d_k \\ \frac{2d_k - b_k}{5} \end{bmatrix} & \text{jeśli } f(x_k + d_k) < f(x_k) \\ \begin{bmatrix} x_k + 2b_k - d_k \\ (7b_k - 2d_k)/5 \end{bmatrix} & \text{jeśli } f(x_k + 2b_k - d_k) < f(x_k) \\ \begin{bmatrix} x_k \\ \frac{1}{2}b_k \end{bmatrix} & \text{wpp} \end{cases}$$

Krok 3: $k += 1$

jeśli kryterium stopu $\rightarrow$ koniec
wpp. $\rightarrow$ Krok 1.

Tempo zbieżności PRS I.

Naszym celem jest szacowanie liczby kroków,
w których $X_k \in S_\varepsilon$.

($\varepsilon > 0$ ustalony, reprezentuje tolerancję na odchylenie)

Niech $\delta(S_\varepsilon) =: \alpha$. Szansa, że nie odwiedzimy
tego zbioru w krokach $1, 2, \dots, n$ wynosi

$$\prod_{k=1}^n (1 - \mathbb{P}(Y_k \in S_\varepsilon)) = (1 - \alpha)^n.$$

Ile kroków jest potrzebnych, by tam trafić z
prawd. (?) $\geq 1 - \varrho$ ($\varrho > 0$ małe)

$$1 - (1 - \alpha)^n \geq 1 - \varrho \Leftrightarrow \varrho \geq (1 - \alpha)^n \Leftrightarrow \log \varrho \geq n \cdot \log(1 - \alpha)$$

$$\Leftrightarrow n \geq \frac{\log \varrho}{\log(1 - \alpha)}$$

Alte $|B(x, \varepsilon)| = c_d \cdot \varepsilon^d$.

Oznaczamy $p(\varepsilon) := \delta(S_\varepsilon)$.

$$N(\varepsilon) = \min \{k : X_k \in S_\varepsilon\} = \min \{k : f(X_k) \leq \varepsilon\}$$

Rozkład $N(\varepsilon)$ jest geometryczny $\text{Geo}(p(\varepsilon))$

$$\Rightarrow \mathbb{E}[N(\varepsilon)] = \frac{1}{p(\varepsilon)}, \quad \text{Var}[N(\varepsilon)] = \frac{1 - p(\varepsilon)}{p(\varepsilon)^2}.$$

Jeszcze: zatem $S_\varepsilon = B(x^*, \varepsilon')$,

$$\text{to } \mathbb{E}[N(\varepsilon)] = \frac{1}{c_d} \cdot \frac{1}{(\varepsilon')^d}$$

Algorytm: Pure Adaptive Search

Krok 0:

Ustalmy $x_0 \in S$ (losowo lub na podstw. wiedzy o problemie)

$$k=0, \quad w_0 = f(x_0)$$

Krok 1:

Losuj x_{k+1} z rozk. jednostajnego na

$$S_k = \{x \in S : f(x) < w_k\}$$

Krok 2:

$k += 1$. Jeśli kryterium stopu spełnione $\rightarrow$ koniec

WPP $\rightarrow$ Krok 1.

Teoria Rekordów.

Niech $X_1, X_2, \dots$ - ciąg zm. iid o wspólnej dystrybucji $F(x)$.

Konstruujemy ciąg zmiennych losowych $N(k)$ w następujący sposób:

$$N(1) = 1$$

$$\begin{aligned} N(k) &= \min \{ j > N(k-1) : X_j > X_{N(k-1)} \} \\ &= \min \{ j > N(k-1) : X_j > \max(X_1, \dots, X_{N(k-1)}) \} \end{aligned}$$

Wtedy:

$$\mathbb{P}(N(k) < \infty) = 1, \text{ zatem } \forall_k \quad p_{n,k} := \mathbb{P}(N(k) = n)$$

więc $p_{n,k}$ jest rozk. prawd. na $\mathbb{N}$.

Lemat 1

Jeśli $F(x)$ to funkcja ciągła, to rozkł. $N(k)$ nie zależy od F .

Dow:

Ćwiczenie.