

STATYSTYKA - Projekt Zaliczeniowy

Franciszek Pietrusiak

2026-01-05

a) Podstawowe omówienie zbioru danych

```
df <- read.csv("Results.csv")
df <- df[df$Age >= 18 & df$Age < 90, ]
```

Tabela `df` opisuje wyniki pojedynczych uczestników maratonów w Stanach Zjednoczonych na przełomie lat 2010 - 2019.

Znalazłem ją pod na kaggle pod tym linkiem.

Każdy rekord w `df` zawiera imię i nazwisko uczestnika (`Name`), płeć (`Gender`), wiek (`Age`), przedział wiekowy (`Age.Bracekt`), czas ukończenia biegu (w sekundach) (`Finish`), nazwę biegu (`Race`), rok w którym odbywał się bieg (`Year`). Tabela zawiera około 2000000 obserwacji i 7 zmiennych.

Niektóre rekordy były błędne, ponieważ zawierały ujemny wiek uczestnika, dlatego wykluczyłem te rekordy z tabeli. Dodatkowo wykluczyłem uczestników z wiekiem większym bądź równym 90, ponieważ jak zakładam, wiele z tych osób celowo ustawiło swój wiek jako 99 będąc znacznie młodszymi, aby np. wygrać daną kategorię wiekową.

Poniżej wyznaczam podstawowe statystyki dla zmiennych w `df`.

```
numeric_variables <- df[c("Age", "Finish", "Year")]

stats_summary <- data.frame(
  Mean = sapply(numeric_variables, mean),
  SD = sapply(numeric_variables, sd),
  min = sapply(numeric_variables, min),
  max = sapply(numeric_variables, max)
)
kable(stats_summary, caption="Podstawowe statystyki dla zmiennych ilościowych")
```

Table 1: Podstawowe statystyki dla zmiennych ilościowych

	Mean	SD	min	max
Age	39.95397	10.862431	18	89
Finish	16514.16392	3371.015169	7425	73460
Year	2014.41625	2.821618	2010	2019

```
# chcę aby 'Under 35' było na początku
df$Age.Bracekt <- as.factor(df$Age.Bracekt)
lev <- levels(df$Age.Bracekt)
df$Age.Bracekt <- factor(
  df$Age.Bracekt,
  levels = c(tail(lev, 1), head(lev, -1))
)
```

```
)
table(df$Age.Bucket)
```

```
##
##      Under 35      35-39      40-44      45-49      50-54      55-59
##      736494      325358      318596      254006      186887      106904
##      60-64      65-69      70-74      75-79 80 and Over
##      54527      21095      7029      1755      375
```

```
table(df$Gender)
```

```
##
##      F      M
## 878440 1134586
```

```
n_distinct(df$Race)
```


```
## [1] 96
```

```
n_distinct(df$Name)
```

```
## [1] 1191781
```

b) Porównanie rozkładu zmiennej Finish dla możliwych wartości zmiennej Age.Bucket.

```
ggplot(df, aes(x=Age.Bucket, y=Finish)) + geom_boxplot()
```



Dodatkowo poniżej zamieszczam tabelkę, w której w podziale na możliwe wartości `Age.Bracekt` wyznaczona jest średnia, mediana, minimum, maximum i odchylenie standardowe zmiennej `Finish`.

```
df %>%
  group_by(Age.Bracekt) %>%
  summarise(
    mean = mean(Finish),
    median = median(Finish),
    min = min(Finish),
    max = max(Finish),
    sd = sd(Finish)
  )
```

```
## # A tibble: 11 x 6
##   Age.Bracekt    mean median   min   max   sd
##   <fct>         <dbl> <dbl> <int> <int> <dbl>
## 1 Under 35      16219.  15914  7425  53764 3295.
## 2 35-39        16253.  15886  7511  48963 3308.
## 3 40-44        16354.  15959  7894  73460 3290.
## 4 45-49        16554.  16127  8217  51661 3325.
## 5 50-54        16862.  16436  8648  49743 3342.
## 6 55-59        17414.  17003  8680  49740 3412.
## 7 60-64        18132.  17737  9764  46982 3487.
## 8 65-69        19121.  18858 10465  46081 3600.
## 9 70-74        20374.  20229 11095  37691 3707.
## 10 75-79       21892.  21827 11162  38319 3801.
## 11 80 and Over 23544.  23491 14190  37440 3887.
```

c) Zależność między zmienną `Finish` a `Age`.

```
model <- lm(Finish ~ Age, df)
beta0 <- coef(model)[1]
beta1 <- coef(model)[2]
```

```
ggplot(df, aes(Age, Finish)) +
  geom_bin2d(bins = 60) +
  scale_fill_viridis_c(trans = "log") +
  geom_abline(slope=beta1, intercept=beta0, col='red')
```




Tabela ma ponad 2 miliony rekordów, dlatego użycie wykresu punktowego jest nieefektywne obliczeniowo i nieczytelne. Zamiast tego użyłem `geom_bin2d()` z biblioteki `ggplot2`.

Kolorem czerwonym zaznaczono model regresji liniowej, gdzie zmienną objaśnianą jest **Finish**, a zmienną objaśniającą **Age**. Na podstawie wykresu można ocenić, że dopasowanie prostej do danych wydaje się rozsądne i czas ukończenia maratonu rośnie liniowo z wiekiem.

d) Dopasowanie rozkładu normalnego do zmiennej $\log(\text{Age})$.

Hipoteza H0: Zmienna $\log(\text{Age})$ ma rozkład normalny.

Hipoteza H1: Rozkład zmiennej $\log(\text{Age})$ istotnie różni się od rozkładu normalnego.

Aby to sprawdzić użyję próbki 500 rekordów z tabeli `df`. Parametry rozkładu normalnego znajduję za pomocą metody największej wiarygodności.

```
df$log_Age <- log(df$Age)

set.seed(123)
df_sample <- sample(df$log_Age, 500)


fit_norm <- fitdist(df_sample, "norm", method="mle")
mu_hat <- fit_norm$estimate["mean"]
sd_hat <- fit_norm$estimate["sd"]
fit_norm

## Fitting of the distribution ' norm ' by maximum likelihood
## Parameters:
##      estimate Std. Error
```

```
## mean 3.6748613 0.012735828
## sd 0.2847818 0.009005091
```

Następnie tworzę wykres kwantylowy dla tego dopasowania.


```
qqnorm(df_sample, main = "Wykres QQ-plot dla zmiennej log(Age)")
qqline(df_sample, col = "red", lwd = 2)
```



A także wykres dystrybucyjny empirycznej z dopasowaną dystrybucją.

```
plot(ecdf(df_sample), main = "Dystrybuanta Empiryczna vs Dopasowana")
curve(
  pnorm(x, mean = mu_hat, sd = sd_hat),
  add = TRUE,
  col = "blue",
  lwd = 2
)
legend(
  "bottomright",
  legend = c("Empiryczna", "Teoretyczna (Normalny)"),
  col = c("black", "blue"),
  lwd = 2
)
```

Dystrybuanta Empiryczna vs Dopasowana



Wynik testu Kołmogorowa-Smirnowa

```
ks_test <- ks.test(df_sample, "pnorm", mean=mu_hat, sd=sd_hat)
ks_test
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data: df_sample
## D = 0.052175, p-value = 0.1314
## alternative hypothesis: two-sided
```

a zatem skoro $p\text{-value} = 0.1314$ jest znacząco większy od 0.05, to nie ma podstaw do odrzucenia hipotezy zerowej H_0 .

e) Dla zmiennych jakościowych estymuję prawdopodobieństwo jej występowania w całej populacji wraz z 99% przedziałem ufności Cloppera-Pearsona

W tej analizie nie uwzględniam zmiennych `Race` oraz `Name`, ponieważ zawierają zbyt wiele różnych wartości i w konsekwencji utworzone tabele byłyby nieczytelne.

```
alfa <- 1 - 0.99
categorical_variables <- c("Gender", "Age.Bricket")

for (col in categorical_variables) {
  tab <- table(df[[col]])
  n_total <- sum(tab)
  x_counts <- as.numeric(tab)
```

```

categories <- names(tab)

p_hat <- x_counts / n_total
# jak w slajdach z wykładu 7
left_end <- qbeta(alfa/2, x_counts, n_total - x_counts + 1)
right_end <- qbeta(1 - alfa/2, x_counts + 1, n_total - x_counts)

table_final <- data.frame(
  Category = categories,
  N = x_counts,
  Prob = p_hat,
  left_end = left_end,
  right_end = right_end
)
print(kable(table_final, caption=paste("Estymacja dla zmiennej", col)))
}

```

```

##
##
## Table: Estymacja dla zmiennej Gender
##
## |Category |      N|      Prob| left_end| right_end|
## |:-----|-----:|-----:|-----:|-----:|
## |F        | 878440| 0.4363779| 0.4354774| 0.4372786|
## |M        | 1134586| 0.5636221| 0.5627214| 0.5645226|
##
##
## Table: Estymacja dla zmiennej Age.Bricket
##
## |Category |      N|      Prob| left_end| right_end|
## |:-----|-----:|-----:|-----:|-----:|
## |Under 35 | 736494| 0.3658641| 0.3649897| 0.3667392|
## |35-39    | 325358| 0.1616263| 0.1609586| 0.1622957|
## |40-44    | 318596| 0.1582672| 0.1576051| 0.1589309|
## |45-49    | 254006| 0.1261812| 0.1255790| 0.1267852|
## |50-54    | 186887| 0.0928388| 0.0923127| 0.0933669|
## |55-59    | 106904| 0.0531061| 0.0526998| 0.0535145|
## |60-64    | 54527 | 0.0270871| 0.0267932| 0.0273832|
## |65-69    | 21095 | 0.0104792| 0.0102953| 0.0106655|
## |70-74    | 7029  | 0.0034918| 0.0033856| 0.0036003|
## |75-79    | 1755  | 0.0008718| 0.0008192| 0.0009268|
## |80 and Over | 375 | 0.0001863| 0.0001624| 0.0002125|

```

f) Model regresji liniowej zmiennej Finish względem zmiennych Age oraz Gender

```

df$Gender <- as.factor(df$Gender)
model <- lm(Finish ~ Age + Gender, df)
model_summary <- summary(model)
model_summary

##
## Call:
## lm(formula = Finish ~ Age + Gender, data = df)
##

```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8874  -2363   -400    1970   57552
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 15315.3096     8.7610  1748.1  <2e-16 ***
## Age          55.0033     0.2117   259.8  <2e-16 ***
## GenderM     -1772.0116     4.6375  -382.1  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3224 on 2013023 degrees of freedom
## Multiple R-squared:  0.08516,    Adjusted R-squared:  0.08516
## F-statistic: 9.369e+04 on 2 and 2013023 DF,  p-value: < 2.2e-16
```

W tym podsumowaniu można zauważyć, że zarówno Age, jak i Gender mają w kolumnie Pr(>|t|) wartości <2e-16, a zatem są to istotne zmienne.

Dodatkowo z tego podsumowania można wywnioskować, że z każdym kolejnym rokiem życia czas ukończenia maratonu wydłuża się średnio o 55 sekund. A także, że mężczyźni biegają średnio o 1772 (co odpowiada 29 minutom i 32 sekundom) sekundy szybciej niż kobiety w tym samym wieku.

Dopasowane współczynniki dla tego modelu wynoszą

```
coef(model)
```

```
## (Intercept)      Age      GenderM
## 15315.30965    55.00328 -1772.01164
```

, a błąd średniokwadratowy to

```
model_summary$sigma^2
```

```
## [1] 10396058
```

co pokazuje dużą rozbieżność wyników od średniej. Wynika to z tego, że w biegach ulicznych startują zarówno amatorzy jak i profesjonalści.

g) Hipotezy statystyczne

Hipoteza 1: Czy płeć ma wpływ na czas ukończenia maratonu?

H0: Średni czas ukończenia maratonu przez mężczyzn i kobiety jest taki sam.

H1: Średni czas ukończenia maratonu istotnie różni się w zależności od płci.

```
test_gender <- t.test(Finish ~ Gender, df)
test_gender
```

```
##
## Welch Two Sample t-test
##
## data: Finish by Gender
## t = 340.51, df = 1886935, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group F and group M is not equal to 0
## 95 percent confidence interval:
##  1577.520 1595.785
## sample estimates:
## mean in group F mean in group M
```

```
##          17408.44          15821.78
```

Przeprowadzony test t-Welcha wykazał statystycznie istotne różnice w czasie ukończenia maratonu ze względu na płeć ($t=340,51$; $df=1886935$; $p\text{-value}<2.2e-16$). Średni czas kobiet ($F=17408,44$) był wyższy niż średni czas mężczyzn ($M=15821,78$). Wynik pozwala na odrzucenie hipotezy zerowej o braku różnic między płciami.

Hipoteza 2: Czy biegacze stają się coraz szybsi?

H0: Średni czas ukończenia maratonu maleje na przestrzeni lat 2010-2019.

H1: Średni czas ukończenia maratonu nie maleje na przestrzeni lat 2010-2019.

Do sprawdzenia tej hipotezy użyję ponownie modelu regresji liniowej. W tym przypadku zmienną objaśnianą jest *Finish*, a objaśniającą *Year*. Jeśli współczynnik nachylenia linii regresji jest ujemny, to zachodzi hipoteza H0, w przeciwnym wypadku zachodzi H1.

```
model_trend <- lm(Finish ~ Year, df)
summary(model_trend)
```

```
##
## Call:
## lm(formula = Finish ~ Year, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9093  -2442   -383    2044   56881
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -3.371e+04  1.696e+03  -19.88  <2e-16 ***
## Year         2.493e+01  8.419e-01   29.62  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3370 on 2013024 degrees of freedom
## Multiple R-squared:  0.0004355, Adjusted R-squared:  0.000435
## F-statistic: 877.1 on 1 and 2013024 DF, p-value: < 2.2e-16
```

Co ciekawe widzimy, że współczynnik nachylenia *Estimate* dla *Year* wynosi $2.493e+01$ oraz wartość $p\text{-value} < 2e-16$, a to oznacza, że średni czas ukończenia maratonu rośnie, a nie maleje!

Jednak wartość *Multiple R-squared: 0.0004355* wskazuje, że zmienna *Year* wyjaśnia zaledwie 0.04% zmienności czasu biegu.

Uzyskany wynik odzwierciedla fakt, że maratony stały się sportem masowym. Z roku na rok na maratony zapisuje się systematycznie rosnąca liczba amatorów, których głównym celem jest “przebiec maraton”. Ta fala nowych, wolniejszych biegaczy przesuwaa średnią w górę, mimo że elita prawdopodobnie wciąż poprawia swoje rekordy.